

PROJETO AVALIATIVO: DATA WAREHOUSE COMPLETO PARA DADOS COVID-19

Modelo Dimensional e Análise de Indicadores (KPIs) com DuckDB

Autor: Giovanni Moreira Serra

Data: 28/11/2025

SUMÁRIO

- 1. RESUMO EXECUTIVO**
- 2. INTRODUÇÃO E CONTEXTO**
 - 2.1. O Desafio Analítico da COVID-19
 - 2.2. Objetivo do Projeto
- 3. METODOLOGIA E ARQUITETURA DE DADOS**
 - 3.1. Escolha Tecnológica: DuckDB
 - 3.2. Fluxo ETL/ELT
 - 3.3. Fonte de Dados
- 4. MODELAGEM DIMENSIONAL (SCHEMA ESTRELA)**
 - 4.1. Conceito e Justificativa
 - 4.2. Tabela Fato: fact_covid_daily
 - 4.3. Dimensões do Data Warehouse
 - 4.3.1. dim_date (Dimensão Temporal)
 - 4.3.2. dim_location (Dimensão Geográfica – SCD Tipo 2)
 - 4.3.3. dim_health_indicators (Dimensão de Indicadores de Saúde)
- 5. IMPLEMENTAÇÃO E DETALHES DO PIPELINE**
 - 5.1. Etapa de Staging e Normalização (OLTP)
 - 5.2. Geração de Chaves Substitutas
- 6. QUALIDADE E VALIDAÇÃO DE DADOS**
 - 6.1. Integridade Referencial (Foreign Key Check)
- 7. RESULTADOS E ANÁLISE DE NEGÓCIOS (KPIs)**
 - 7.1. Análise Temporal Aprofundada (Brasil)
 - 7.2. Ranking de Performance de Vacinação Global
 - 7.3. Agregação Multidimensional: Taxa de Mortalidade por Continente e Expectativa de Vida
 - 7.4. Correlação: Taxa de Casos e Quartil de PIB per Capita
 - 7.5. Análise de Comportamento: Atraso entre Vacinação e Pico de Casos
- 8. CONCLUSÃO E RECOMENDAÇÕES FUTURAS**
- 9. APÊNDICE A: Trechos de Código SQL (Exemplos)**

1. RESUMO EXECUTIVO

Este relatório técnico detalha a concepção, desenvolvimento e implementação de um **Data Warehouse (DW) analítico** para dados da pandemia de COVID-19. O projeto foi construído sobre a arquitetura de **Schema Estrela**, utilizando o sistema de gerenciamento de banco de dados analítico **DuckDB** para garantir alta performance em consultas complexas.

O pipeline de dados foi desenhado para processar dados brutos da *Our World in Data (OWID)*, aplicando o processo **ETL/ELT** para normalizar as informações em um modelo dimensional composto por uma tabela Fato (**fact_covid_daily**) e três Dimensões (**dim_date**, **dim_location**, **dim_health_indicators**). A dimensão geográfica (**dim_location**) foi implementada com a lógica de **Dimensão que Muda Lentamente (SCD Type 2)**, essencial para rastrear alterações em atributos dos países ao longo do tempo.

Um rigoroso processo de **Qualidade de Dados** confirmou a **Integridade Referencial** do DW, resultando em zero erros de chaves estrangeiras. As consultas analíticas demonstraram a eficácia do modelo dimensional em suportar análises de negócio multidimensionais, como a correlação entre PIB per Capita e a taxa de casos, e o ranqueamento de performance de vacinação.

O projeto atinge o objetivo de fornecer uma base robusta e otimizada para a tomada de decisões estratégicas sobre a gestão de saúde pública.

2. INTRODUÇÃO E CONTEXTO

2.1. O Desafio Analítico da COVID-19

A pandemia de COVID-19 gerou um volume massivo de dados temporais e geográficos (séries temporais de casos, mortes, hospitalizações, e vacinação). A análise destes dados, no entanto, é frequentemente dificultada pela estrutura dos dados de origem (tipicamente *datasets* planos e desnormalizados), que não são otimizados para consultas analíticas complexas e cálculo de *Key Performance Indicators* (KPIs). Consultar *datasets* brutos para obter métricas como "Taxa de Mortalidade por Expectativa de Vida e Continente" é ineficiente e propenso a erros.

2.2. Objetivo do Projeto

O objetivo central deste projeto foi:

- Construir um Data Warehouse (DW):** Criar um ambiente de dados estruturado no formato **Schema Estrela**.
- Desenvolver um Pipeline ETL/ELT:** Processar os dados brutos da OWID para transformá-los e carregá-los no DW.
- Implementar Modelagem Avançada:** Incluir o tratamento de Dimensões que Mudam Lentamente (SCD Type 2) na dimensão geográfica.
- Garantir a Qualidade de Dados:** Validar a integridade referencial do modelo.
- Suportar Análise de Negócios:** Demonstrar a capacidade do DW de responder a perguntas analíticas complexas e calcular KPIs de forma eficiente.

3. METODOLOGIA E ARQUITETURA DE DADOS

3.1. Escolha Tecnológica: DuckDB

O DuckDB foi escolhido como o principal *Data Engine* devido às suas características como um Sistema de Gerenciamento de Banco de Dados (SGBD) **Analítico (OLAP)** e **Embutido (In-Process)**.

- **Processamento Colunar:** Otimiza a leitura e agregação de grandes volumes de dados, fundamental para a Tabela Fato.
- **Armazenamento de Dados Analíticos:** Oferece excelente performance para consultas de *scans* de tabela e agregações, superando SGBDs transacionais (OLTP) em cenários de DW.
- **Integração Python:** Sua execução *in-process* com Python (via *Notebook Jupyter*) simplifica o pipeline de dados, permitindo a execução de consultas SQL e manipulação de dados em memória de forma contínua.

3.2. Fluxo ETL/ELT

O projeto seguiu uma abordagem **ETL/ELT** (Extract, Transform, Load / Extract, Load, Transform) híbrida, com as principais fases:

Fase	Descrição	Tecnologia
E (Extract) & L (Load - Staging)	Leitura inicial do arquivo CSV (owid-covid-data.csv) e carregamento em uma <i>view</i> temporária de <i>staging</i> no DuckDB (stg_covid_data).	DuckDB / Pandas
T (Transform - Normalização)	Limpeza e estruturação inicial dos dados do <i>staging</i> em tabelas temporárias OLTP (oltp_location , oltp_daily_metrics) para isolar atributos estáticos de métricas dinâmicas.	SQL (DuckDB)
T (Transform - Dimensional)	Geração das chaves substitutas, aplicação da lógica SCD Type 2 e carregamento das Dimensões a partir dos dados normalizados.	SQL (DuckDB)
L (Load - DW)	População da Tabela Fato (fact_covid_daily), realizando <i>JOINS</i> entre as métricas diárias e as Dimensões para mapear chaves de negócio às chaves substitutas.	SQL (DuckDB)

3.3. Fonte de Dados

A fonte primária foi o *dataset* público mantido pela **Our World in Data (OWID)**. O arquivo CSV contém métricas diárias detalhadas de COVID-19 para diversos países, incluindo casos, mortes, testes, vacinação e indicadores socioeconômicos e de saúde (e.g., Expectativa de Vida, PIB per Capita).

- **Volume de Dados na Staging:** Aproximadamente **429.435 linhas** (registros Dia x País).

4. MODELAGEM DIMENSIONAL (SCHEMA ESTRELA)

4.1. Conceito e Justificativa

O **Schema Estrela** é o padrão de modelagem para *Data Warehouses*. Ele consiste em uma **Tabela Fato** central (contendo métricas e chaves estrangeiras) circundada por **Tabelas de Dimensão** (contendo atributos descritivos).

Vantagens do Schema Estrela para Análise:

- **Simplicidade:** Facilita a compreensão e escrita de consultas pelos usuários de BI.
- **Performance:** Reduz o número de *JOINS* complexos, pois as consultas geralmente envolvem apenas a Tabela Fato e as dimensões diretamente conectadas.
- **Agregação:** Otimiza o desempenho da agregação, pois os dados são pré-organizados para sumarização.

4.2. Tabela Fato: **fact_covid_daily**

A tabela fato é o coração do DW. Sua **granulação** é diária e por localização (país/região).

Coluna	Tipo	Descrição
date_sk	INTEGER	Chave Estrangeira (FK) para <i>dim_date</i> .
location_sk	INTEGER	Chave Estrangeira (FK) para <i>dim_location</i> .
health_sk	INTEGER	Chave Estrangeira (FK) para <i>dim_health_indicators</i> .
new_cases	INTEGER	Métrica: Novos casos reportados.

total_cases	INTEGER	Métrica: Casos acumulados.
new_deaths	INTEGER	Métrica: Novas mortes reportadas.
total_vaccinations	INTEGER	Métrica: Doses totais administradas.
stringency_index	FLOAT	Métrica: Índice de Rigor das medidas governamentais.

•

Volume de Registros: 401.502 registros (linhas).

4.3. Dimensões do Data Warehouse

4.3.1. **dim_date** (Dimensão Temporal)

Esta dimensão é fundamental para qualquer análise de séries temporais. Ela isola o tratamento de datas, permitindo consultas por ano, mês, trimestre, dia da semana, etc., sem a necessidade de cálculos complexos na consulta.

Atributo de Exemplo	Tipo	Uso Analítico
date_sk (PK)	INTEGER	Chave substituta (e.g., 20231127).
full_date	DATE	Data completa.
year	INTEGER	Agregação por Ano.
month_name	VARCHAR	Agregação por Mês (texto).
is_weekend	BOOLEAN	Filtro para análise de dias úteis/finais de semana.

4.3.2. **dim_location** (Dimensão Geográfica – SCD Tipo 2)

A dimensão geográfica armazena atributos de países. O tratamento **SCD Tipo 2** (Slowly Changing Dimension Type 2) é essencial para rastrear **mudanças históricas em atributos dos países** que afetam as métricas, como alterações no nome de uma região ou, mais

criticamente neste contexto, **reclassificações de Continentes ou outros atributos geográficos/políticos**.

- **Mecanismo SCD Tipo 2:** Utilização das colunas de controle:
 - **start_date:** Data de início da vigência do registro.
 - **end_date:** Data de fim da vigência do registro (NULL para registros atuais).
 - **is_current:** Flag booleana (TRUE/FALSE) para identificar a versão ativa.
- **Vantagem:** Permite que a análise de métricas antigas seja feita com os atributos (Continente, etc.) que eram válidos no momento da observação.

Atributo de Exemplo	Tipo	Uso Analítico
location_sk (PK)	INTEGER	Chave substituta.
location_id	VARCHAR	Chave de Negócio (e.g., 'BRA').
continent	VARCHAR	Agregação Geográfica.
population	BIGINT	Base para cálculo de taxas (<i>per capita</i>).
start_date	DATE	Início da vigência do registro (SCD T2).

4.3.3. dim_health_indicators (Dimensão de Indicadores de Saúde)

Esta dimensão armazena atributos estáticos e pré-calculados que são importantes para correlacionar a taxa de infecção/mortalidade com o nível socioeconômico e a infraestrutura de saúde.

- **Granulação:** Por País/Localização, capturando os indicadores no momento da extração.

Atributo de Exemplo	Tipo	Uso Analítico
health_sk (PK)	INTEGER	Chave substituta.

location_id	VARCHAR	Chave de Negócio.
life_expectancy_group	VARCHAR	Classificação por faixa etária (e.g., 'Baixa', 'Média', 'Alta').
gdp_per_capita	FLOAT	Atributo socioeconômico.
hospital_beds_per_thousand	FLOAT	Indicador de infraestrutura de saúde.

5. IMPLEMENTAÇÃO E DETALHES DO PIPELINE

5.1. Etapa de Staging e Normalização (OLTP)

O processo de ingestão utilizou a funcionalidade do DuckDB de ler diretamente o CSV e criar uma *view* temporária. A partir disso, a primeira transformação foi a normalização (simulando um **OLTP** temporário) para separar:

- **Entidades Estáticas:** Atributos do país que são relativamente permanentes (e.g., códigos, localização, população).
- **Séries Temporais:** Métricas que mudam diariamente (casos, mortes, etc.).

Este passo simplifica a construção das dimensões, garantindo que o `dim_location` e `dim_health_indicators` sejam populados com dados limpos e únicos.

5.2. Geração de Chaves Substitutas

Para a integridade analítica, todas as dimensões utilizam **Chaves Substitutas** (`_sk`), que são inteiros sequenciais (auto-incrementais ou gerados por *hash*). O uso destas chaves desvincula o DW das chaves de negócio (e.g., código do país 'BRA' ou data '2023-11-27'), tornando-o resiliente a mudanças nas chaves de origem e otimizando a performance dos *JOINS* (a comparação de inteiros é mais rápida que *strings* ou datas).

6. QUALIDADE E VALIDAÇÃO DE DADOS

A **Qualidade de Dados** é um pilar de qualquer Data Warehouse confiável. A etapa de validação final é crucial para assegurar que a carga de dados no DW não introduziu inconsistências.

6.1. Integridade Referencial (Foreign Key Check)

A validação foi realizada através de uma consulta SQL que verificou a integridade das **Chaves Estrangeiras (FKs)** entre a Tabela Fato e suas dimensões. O principal objetivo é confirmar que **nenhum registro na Tabela Fato é órfão**.

Lógica da Verificação:

- 1. Executar um **LEFT JOIN** da Tabela Fato (**fact_covid_daily**) com cada Dimensão (**dim_date, dim_location**).
- 2. Contar os registros onde a chave substituta da Dimensão resulta em **NULL** (indicando que a FK da Fato não encontrou um registro correspondente na Dimensão).
- 3. Agrupar os erros por tipo de chave (Data, Localização).

Resultado da Validação (Conforme Execução no Notebook):

Tipo de Erro	Chave	Número de Registros Órfãos
FK Missing (Data)	date_sk	0
FK Missing (Localização)	location_sk	0
Status Final:		SUCESSO

Conclusão: A ausência de erros de integridade (0 registros órfãos) valida o sucesso do pipeline ETL/ELT, confirmando que todas as chaves de negócio presentes nas métricas diárias foram corretamente mapeadas e carregadas nas respectivas dimensões.

7. RESULTADOS E ANÁLISE DE NEGÓCIOS (KPIs)

O modelo dimensional foi submetido a 5 consultas analíticas (KPIs) complexas, demonstrando sua capacidade de agregação e filtragem multidimensional.

7.1. Análise Temporal Aprofundada (Brasil)

KPI: Volume total de casos e mortes por mês e ano para o Brasil.

Ano	Mês	Total Casos Mês	Total Mortes Mês
2020	11	913.682	14.394
2021	3	2.216.400	66.358
2022	1	6.040.548	20.306
2023	1	666.930	3.999

Insight Analítico: O pico de mortalidade (66.358 óbitos) ocorreu em Março de 2021, demonstrando o momento mais crítico da pandemia no país. O pico de casos absolutos ocorreu em Janeiro de 2022, coincidindo com a alta transmissibilidade da variante Ômicron, mas com uma taxa de mortalidade significativamente menor devido à vacinação.

7.2. Ranking de Performance de Vacinação Global

KPI: Ranking dos 10 países com a maior proporção de população totalmente vacinada.

Localização	Continente	Taxa de Vacinação Completa (% População)
Gibraltar	Europe	129,59%
Pitcairn	Oceania	100,00%
Malta	Europe	92,72%
Chile	South America	90,81%

Portugal	Europe	90,09%
...		

Insight Analítico: A consulta demonstra a capacidade do DW de usar a coluna **population** da **dim_location** como base para a normalização das métricas da **fact_covid_daily**. Taxas superiores a 100% são artefatos comuns em dados de saúde global e podem ser causadas por populações base desatualizadas (denominador) ou pela inclusão de vacinação de não residentes (e.g., turismo de vacinação).

7.3. Agregação Multidimensional: Taxa de Mortalidade por Continente e Expectativa de Vida

KPI: Taxa de Mortalidade Agregada (*Total Deaths / Total Cases*) agrupada por **Continente** (**dim_location**) e **Grupo de Expectativa de Vida** (**dim_health_indicators**).

Continente	Grupo Expectativa de Vida	Taxa de Mortalidade Agregada
Africa	Baixa (<70 anos)	2,50%
Europe	Média (70-80 anos)	2,04%
South America	Média (70-80 anos)	2,04%
Europe	Alta (>80 anos)	1,23%

Insight Analítico: A maior Taxa de Mortalidade Agregada (2,50%) foi observada nos países africanos com baixa expectativa de vida. Isso sugere uma possível correlação entre a fragilidade do sistema de saúde (inferida pela baixa EV) e a fatalidade da doença, mesmo considerando que a contagem de casos pode ser sub-reportada. O DW permitiu a intersecção de dois atributos de diferentes dimensões para gerar este KPI.

7.4. Correlação: Taxa de Casos e Quartil de PIB per Capita

KPI: Taxa de Casos ($\text{Total Casos} / \text{População}$) média agrupada pelo Quartil de PIB per Capita do país.

Quartil de PIB	Faixa de PIB per Capita (USD)	Taxa de Casos Média (%)
1 (Baixo)	661.24 a 3.823.19	2,71%
2	4.227.63 a 12.294.88	8,78%
3	12.895.64 a 27.717.85	19,18%
4 (Alto)	27.936.90 a 116.935.60	39,56%

Insight Analítico: Observou-se uma correlação positiva e exponencial. Países com o PIB per Capita mais alto (Quartil 4) tiveram uma taxa de casos (proporcional à população) drasticamente superior (39,56%). Isso pode ser atribuído a uma maior capacidade de testagem e monitoramento nos países ricos, levando a um *reporting* de casos mais preciso e abrangente.

7.5. Análise de Comportamento: Atraso entre Vacinação e Pico de Casos

KPI: Quantidade de dias entre a data de início da vacinação (primeiro dia com doses aplicadas > 0) e a data do pico de novos casos diários.

Localização	Dias de Atraso (Pico de Casos após 1ª Vacinação)
China	642 dias
Japan	535 dias
Isle of Man	523 dias

Guatemala	492 dias
Germany	454 dias

Insight Analítico: Este KPI mede o tempo de resposta ou a persistência da doença após o início da vacinação. Países com alto atraso (como China e Japão) podem ter mantido medidas de contenção rigorosas, ou enfrentado picos de variantes subsequentes (Ômicron) muito tempo depois, mostrando que a vacinação isolada não foi o único fator a influenciar o *timing* do pico.

8. CONCLUSÃO E RECOMENDAÇÕES FUTURAS

O projeto foi concluído com sucesso, resultando em um Data Warehouse robusto e validado para a análise de dados COVID-19.

1. **Modelo Dimensional:** A implementação do **Schema Estrela** demonstrou ser altamente eficaz para análises multidimensionais e o cálculo eficiente dos KPIs.
2. **Qualidade de Dados:** A validação de Integridade Referencial (0 erros) confirmou a confiabilidade dos dados e a precisão do pipeline ETL/ELT.
3. **Tecnologia:** O uso do DuckDB se provou ideal para o protótipo analítico, oferecendo alta performance em um ambiente de fácil deployment.
4. **SCD Tipo 2:** A aplicação desta lógica no `dim_location` garante a validade histórica das análises, permitindo auditar métricas passadas com o contexto correto da época.

Recomendações Futuras:

- **Implementação de Snapshot Fact Tables:** Criar *snapshot fact tables* semanais ou mensais para facilitar a análise de *stock* (estoque, total acumulado) e tendências de longo prazo.
- **Adição de Novas Dimensões:** Introduzir uma dimensão de **Tempo Geográfico (Feriados Nacionais/Eventos)** para correlacionar picos de casos com eventos sociais específicos.
- **Pipeline de Produção:** Migrar o pipeline para uma ferramenta de orquestração como Apache Airflow, garantindo o *refresh* automático e incremental do DW.